

Lab 09: Triển khai hệ thống phân tích và xử lý dữ liệu lớn

(Castone Project)

Mục tiêu:

- Tìm hiểu Uses case về triển khai hệ thống dữ liệu lớn.
- Biết cách vận dụng kỹ thuật phân tích và xử lý dữ liệu.
- Biết cách triển khai hệ thống Castone Project theo các bước, các tài liệu trong việc triển khai hệ thống.
- Xây dựng, triển khai hệ thống dữ liệu lớn với bài toán cụ thể.
- Kiểm tra kết quả thực hiện trên màn hình giao diện ứng dụng.
- Submit kết quả thực hiện Project lên hệ thống (LMS Canvas, Github, jupyter notebook...)

Nội dung:



1. Tìm hiểu bài toán:

- Bài toán:

Một trong những tập đoàn lớn cần dịch vụ kỹ thuật dữ liệu cho dữ liệu nhân viên trong một thập kỷ. Tất cả các tập dữ liệu nhân viên trong giai đoạn đó được cung cấp trong sáu tệp CSV. Bước đầu tiên của dự án này là tạo Biểu đồ quan hệ thực thể và tạo cơ sở dữ liệu trong RDBMS với tất cả các bảng để cấu trúc và lưu trữ dữ liệu theo các mối quan hệ giữa các bảng. Nhập các tệp CSV vào cơ sở dữ liệu MySQL, chuyển sang HDFS/Hive ở định dạng được tối ưu hóa và phân tích bằng Hive, Impala, Spark và SparkML. Cuối cùng, viết một tập lệnh Bash để tạo điều kiện thuận lợi cho pipeline dữ liệu đầu cuối và pipeline học máy cho việc tự động hóa.

- Xử lý:

Nhập dữ liệu từ MySQL RDBMS sang HDFS bằng Sqoop, Tạo bảng HIVE với định dạng tệp nén.

- Phân tích dữ liệu giải thích bằng Impala & SparkSQL.
- Xây dựng mô hình phân loại rừng ngẫu nhiên & Mô hình hồi quy logistic bằng SparkML.

Business Objectives

- Basic Exploratory Analysis on different metrics available to get insights at the Employee level as well as Department levels.
- To analysis the various factors connected to the Employee's Leaving and improve on those parameters viz Salary, Last Performance Ratings, Years of Service (Tenure), No of projects etc.
- Technology-wise Objective : **Creating an End-to-End Pipeline** to enhance the automation to do quick analysis and manage all the repetitive actions in a proper-structured manner.

Data Description

1. Titles (titles.csv):

- a. **title_id** – Unique id of type of employee (designation id) – Character – Not Null
- b. **title** – Designation – Character – Not Null

2. Employees (employees.csv):

- a. **emp_no** – Employee id – Integer – Not Null
- b. **emp_title_id** – designation id – Not Null
- c. **birth_date** – Date of Birth – Date Time – Not Null
- d. **first_name** – First Name – Character – Not Null
- e. **last_name** – Last Name – Character – Not Null
- f. **sex** – Gender – Character – Not Null
- g. **hire_date** – Employee Hire date – Date Time – Not Null
- h. **no_of_projects** – Number of projects worked on – Integer – Not Null
- i. **Last_performance_rating** – Last year performance rating – Character – Not Null
- j. **left** – Employee left the organization – Boolean – Not Null
- k. **Last_date** – Last date of employment (Exit Date) – Date Time

3. Salaries (salaries.csv):

- a. **emp_no** – Employee id – Integer – Not Null
- b. **Salary** – Employee's Salary – Integer – Not Null

4. Departments (departments.csv)

- a. **dept_no** – Unique id for each department – character – Not Null
- b. **dept_name** – Department Name – Character – Not Null

5. Department Managers (dept_manager.csv)

- a. **emp_no** – Unique id for each department – character – Not Null
- b. **emp_no** – Employee number (head of the department) – Integer – Not Null

6. Department Employees (dept_emp.csv)

- a. **emp_no** – Employee id – Integer – Not Null
- b. **dept_no** – Unique id for each department – character – Not Null


Data Description

This dataset has total 6 tables (Records) –


1. Employees (300024),
2. Salaries (300024),
3. Titles (7),
4. Dept_Emp (331603 -> 300024),
5. Dept_Manager (24) and
6. Departments (9).

Technology Stack

- **Linux Commands** (to run the bash script)
- **MySQL** (to create database - RDBMS)
- **Sqoop** (Transfer data from MySQL Server to HDFS/Hive)
- **HDFS** (to store the data)
- **Hive** (to create database)
- **Impala** (to perform the EDA)
- **SparkSQL & PySpark** (to perform the EDA)
- **SparkML** (to perform model building)
- **git** (for version control)



Architecture of pipeline



2. Đọc tài liệu trong file đính kèm ([File đính kèm](#))
3. Chuẩn bị các tài liệu theo như trong dự án mẫu.
4. Triển khai xây dựng hệ thống theo các bước
5. Submit kết quả trên hệ thống